

基于集群划分的短期风电功率预测方法

王 勃¹, 刘 纯¹, 冯双磊¹, 丘 刚², 孟祥星³, 赵俊屹⁴

- (1. 中国电力科学研究院有限公司新能源与储能运行控制国家重点实验室, 北京 100192;
2. 国网新疆电力有限公司, 乌鲁木齐 830063; 3. 国网黑龙江省电力有限公司, 哈尔滨 150090;
4. 国网山西省电力有限公司, 太原 030001)

摘 要: 风电功率预测的快速全覆盖对区域风电的优化调度意义重大, 现有预测算法均无法解决这一问题。为此, 采用模糊聚类分析实现对风电场出力特性的有效识别和风电场集群的合理划分, 将主成分分析用于区域空间特征气象参数的提取, 建立了基于集群划分的区域风电功率预测技术框架。算例结果表明, 单个集群的预测精度略低于传统逐风电场建模的预测精度; 随着预测范围的扩大, 区域集群预测与传统预测方法的精度相当, 但建模量明显减少。基于集群划分的短期风电功率预测方法可在保证预测精度的同时, 显著提升建模效率。

关键词: 风电场; 功率预测; 数值天气预报; 集群划分; 模糊聚类分析

Prediction Method for Short-term Wind Power Based on Wind Farm Clusters

WANG Bo¹, LIU Chun¹, FENG Shuanglei¹, QIU Gang², MENG Xiangxing³, ZHAO Junyi⁴

- (1. State Key Laboratory of Operation and Control of Renewable Energy & Storage Systems,
China Electric Power Research Institute, Beijing 100192, China;
2. State Grid Xinjiang Electric Power Company Limited, Urumqi 830063, China;
3. State Grid Heilongjiang Electric Power Company Limited, Harbin 150090, China;
4. State Grid Shanxi Electric Power Company Limited, Taiyuan 030001, China)

Abstract: The fast-full coverage of regional wind farms of wind power prediction is very important for optimal scheduling of wind farms; the existing prediction algorithms are unable to solve this problem. Consequently, we adopted fuzzy clustering analyses to achieve an effective recognition of the wind power characteristics and a reasonable division of wind farm clusters. The principal component analysis was used to extract the region weather characteristic parameters, and a framework of wind power prediction method was established based on clusters. The results show that the prediction accuracy of a single cluster is slightly lower than the traditional method which models for each wind farm, with the expansion of the forecast range, the prediction accuracy will reach the level of the traditional method. The prediction method based on wind farm clusters can ensure the prediction accuracy, at the same time, achieve a significant efficiency improvement compared to the traditional method.

Key words: wind farm; power prediction; numerical weather prediction; cluster; fuzzy clustering analysis

0 引言

能源是经济社会可持续发展的基础, 高效、清洁、低碳已成为世界能源发展的主流方向。在相关政策的支撑下, 我国风电自 2006 年起呈爆发式增长, 截止 2015 年底, 风电累计装机容量已达 1.29 亿千瓦, 占全部发电装机容量的 8.6%, 装机容量居

世界首位^[1]。我国风电多为大规模、集中式开发, 给系统的电力电量平衡带来较大困难。风电功率预测作为一种可提前预知风电场输出功率波动情况的技术, 可有效降低风电功率的不确定性, 是实现风电优化调度和高效消纳的基础^[2-3]。

国外在风电功率预测领域已开展多年的研究, 提出了大量风电功率预测方法^[4], 如统计预测方法^[5]、物理预测方法^[6]、统计与物理相结合的混合预测法^[7]、集合预测方法^[8-9]等。近年来, 随着国内风电装机容量的增大, 以及调度机构对预测精度考核力度的加大, 风电功率预测已成为研究热点, 涌

基金资助项目: 北京市科技计划项目(Z161100002616039); 国家电网公司科技项目(5442NY170023)。
Project supported by the Science and Technology Project of Beijing (Z161100002616039), Science and Technology Project of SGCC (5442NY170023).

现出大量先进的预测算法。文献[10]提出了可用于新建风电场建模的物理预测方法; 文献[11]研究了天气分型理论, 提出了基于天气分型的风电功率预测算法; 此外, 较为先进的预测算法还包括多层次综合预测法^[12]、支持向量回归机^[13]、非迭代-分时段最优预测模型^[14]、统计升尺度法^[15-16]等。上述研究在风电功率预测领域进行了有益的探索, 提出了大量先进的算法, 实现了对单个风电场功率的准确预测, 但是, 已有研究均集中在对单个风电场的预测算法改进及模型完善方面, 文献[15-16]虽然试图以代表风电场线性外推的方式解决区域风电功率预测问题, 但其研究重点仍集中在对代表风电场的预测完善上。

风电功率预测主要用于发电计划的制定, 区域风电与常规电源的协调优化调度需要保证对区域内所有风电场的预测快速全覆盖, 现有预测方法无法解决这一问题: 第 1, 我国风电场建设速度快, 基础条件参差不齐, 难以保证所有风电场都具备建立准确预测模型的条件; 第 2, 现有预测方法均采用离线建模的方式, 而收资及建模的周期一般在一个月以上, 在此期间, 风电功率预测系统处于不完整状态; 第 3, 区域风电场间功率变化趋势具有一致性, 但同一时刻不同场站间功率差异仍然较大, 以典型风电场出力的线性外推替代区域风电出力可能引入较大的预测误差。

本文提出以集群预测解决区域风电功率预测快速全覆盖问题的技术框架, 研究了区域风电的出力特性, 采用模糊聚类分析对风电场集群进行有效划分; 分析了数值天气预报(NWP)的空间相关性, 采用主成分分析方法实现了对区域气象参数的空间特征提取; 建立了不同集群的功率预测模型; 最后, 通过算例验证了算法的准确性和技术路线的可行性。

1 基于集群划分的风电功率预测基本框架

1.1 风电功率预测原理

风电功率预测是以风电场基础信息、历史运行数据、实测气象数据以及 NWP 等数据为基础, 通过挖掘 NWP 数据与风电场历史功率的关系来构建预测模型, 并以未来的 NWP 数据作为模型的输入, 从而对风电场未来一段时段内有功功率变化进行预测的方法。人工神经网络具有分布式并行处理、非线性映射、自适应学习、鲁棒容错和泛化能力等优点, 是风电功率预测中应用最广泛的方法^[17]。

1.2 计算框架

传统风电功率预测理论认为: 预测单元越小, 预测结果中包含的信息越完整, 在区域平滑效应的作用下^[18], 由单个预测单元累加得到的区域预测结果精度更高。因此, 目前的省级风电功率预测系统的最小预测单元均为单个风电场, 全省功率预测结果由单个风电场预测结果累加得到。事实上, 预测单元越小, 功率序列中的高频脉动越剧烈, 而此类因局地效应引起的随机波动在 NWP 中是无法体现的, 因此, 预测模型难以捕捉此类波动。随着区域的增大, 具有相似出力特性的风电场群将平滑这种随机波动, 在宏观上表现为区域风电的出力曲线更为平滑, 且趋势性更强。因此, 若能对区域风电场进行有效划分, 并针对具备特定功率特性的风电场群进行集中建模, 则可在不损失预测精度的前提下显著提高建模效率。

本文提出的基于集群划分的功率预测计算框架如图 1 所示。首先, 以风电场历史功率序列为基础, 采用模糊聚类分析的方法将风电场划分为若干集群; 针对每个聚群, 提取其对应风电场的 NWP 数据, 并采用主成分分析提取其空间特征气象参数; 以特征气象参数为输入, 针对每个集群分别建立神经网络预测模型; 最后由各集群预测功率的累加得到整个区域的风电预测功率。

1.3 数据说明

本文选择山东已投运>1 a 的 34 座风电场进行分析。使用的数据包括风电场有功功率数据、NWP 数据等, 数据由运行于山东电力公司的“中国电科院风电功率预测系统(WPFS)”获取, 数据长度为 2013-01-01T00:00—2013-12-31T23:45, 共 1 个

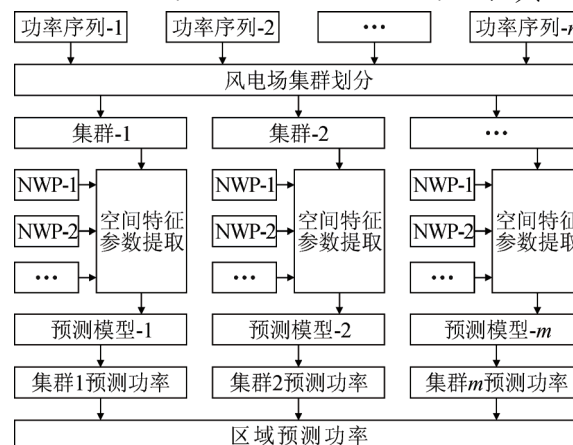


图 1 基于集群划分的风电功率预测计算框架

Fig.1 Framework of wind power prediction method based on clusters

完整年, 时间分辨率为 15 min。

2 风电场集群划分方法

2.1 风电场出力特性分析

在大气环流作用下, 不同地域的天气总体变化趋势与大气环流运动趋势保持一致, 与此同时, 受局地效应及大气运动时滞性的影响, 不同区域的天气变化又呈现特有的“个性”。风电场的功率变化完全由天气条件决定, 在大气运动“趋势性”与“个性”的共同作用下, 区域风电功率在保持规律性的同时, 不同风电场呈现较大差异。图 2 为某典型日 34 个风电场有功功率的时序变化及分布情况, 可见, 在不考虑时滞性的影响下, 不同风电场的有功功率总体呈现 2 种变化趋势: 一种为总体平稳变化 (图 2(a)中粗实线), 另一种为钟形变化 (图 2(a)中点划线)。与此同时, 在局地效应的作用下, 不同风电场的功率衍生出特有的波动特性, 导致风电场有功功率呈现较大的差异化。图 2(b)为不同风电场日功率的分布情况, 可见, 不同风电场间的日功率中位数及变化范围差别巨大, 如 6 号风电场的功率仅在装机容量的 50% 范围内波动, 而 26 号风电场的波动范围介于切入和满发之间, 因此, 地域分布引起的风电场出力特性差异非常显著。

2.2 基于模糊聚类的风电场集群划分

如上所述, 区域风电功率在保持一定规律性的同时, 在局地动力和热力综合作用下会呈现较大的差异性。合理的集群划分方案应满足以下条件: 第 1, 应考虑风电场所处区域的地形地貌、气候特征, 保证集群内风电场具备相似的出力特性; 第 2, 应尽量减少集群划分数量, 提高建模的效率; 第 3, 应考虑电网调峰以及关键断面约束的限制, 集群内风电场应划分在同样的电网断面内, 避免跨电网断面约束的集群划分。

事实上, 风电场出力的差异并没有明确的界限, 为了从资源角度对风电场群进行有效划分, 本文以风电场功率序列为基础, 通过计算不同功率序列间的距离, 以集群内距离最小化、集群间距离最大化为优化目标, 实现对风电场集群的划分, 在此基础上, 根据电网拓扑结构, 对风电场所属集群进行微调。集群划分采用的方法为模糊聚类。

模糊聚类分析^[9]是一种应用广泛的聚类方法, 相对传统的硬聚类方法, 模糊聚类引入隶属度的概念, 各样本以一定的隶属度从属于不同聚类, 可据

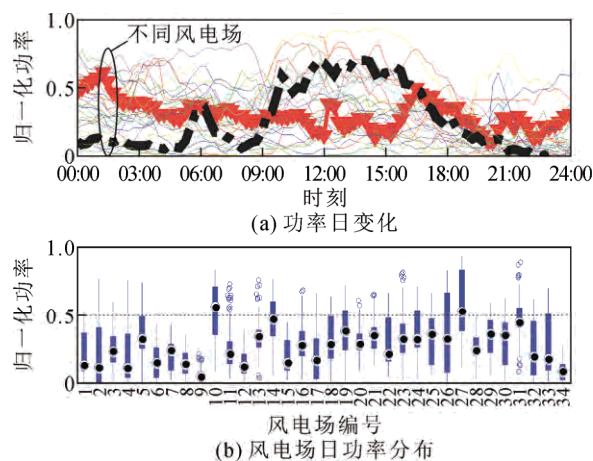


图 2 功率的日变化及分位数分布

Fig.2 Power diurnal variation and quantile distribution

此将样本划分为若干互不相交的子集。记观测数据矩阵为

$$\mathbf{X} = [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_s]^T \quad (1)$$

式中: $\mathbf{x}_i = [x_{i1} \quad x_{i2} \quad \cdots \quad x_{is}]$, x_{ib} 为第 i 个变量的第 b 次观测结果, $i=1, 2, \cdots, n$; s 为变量个数。

定义目标函数为

$$J(\mathbf{U}, \mathbf{V}) = \sum_{k=1}^M \sum_{j=1}^c u_{jk}^2 d_{jk}^2 \quad (2)$$

式中: \mathbf{V} 为聚类中心矩阵, $\mathbf{V} = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_c]$, \mathbf{v}_a 为第 a 类的聚类中心; $\mathbf{U} = (u_{jk})_{c \times M}$ 为隶属度矩阵, u_{jk} 为第 k 个样品 \mathbf{x}_k 从属于第 j 类的隶属度; $d_{jk} = \|\mathbf{x}_k - \mathbf{v}_j\|$, 为样品 \mathbf{x}_k 与聚类中心 \mathbf{v}_j 的欧拉距离; c 为聚类个数; M 为样品个数。

模糊聚类以初始化聚类中心为基础, 通过不断更新隶属度矩阵和聚类中心, 并以目标函数最小化为优化目标, 最终获得类别划分。聚类中心和隶属度更新方法如下:

$$\mathbf{v}_j^{(l)} = \frac{\sum_{k=1}^M u_{jk}^{(l-1)} \mathbf{x}_k}{\sum_{k=1}^M u_{jk}^{(l-1)}} \quad (3)$$

$$u_{jk}^{(l)} = 1 / \sum_{a=1}^c (d_{jk}^{(l)} / d_{ak}^{(l)})^2 \quad (4)$$

式中 l 为迭代次数。

3 NWP 的空间特征提取

3.1 NWP 的空间相关性分析

大气在运动过程中受地形、地表粗糙度、障碍物及局地热力效应的影响, 风速、风向、气压等气

象参数均会发生变化。NWP 是通过数值求解的方式定量、客观预报大气演变过程的方法, 由于在求解过程中已考虑地形、粗糙度等因素的影响, 因此在数值模式设置合理的情况下, NWP 可实现对局地效应引起的差异化气象参数的有效捕捉。

图3显示了不同空间位置对应的NWP中100 m 层风速间的相关性系数随距离的变化情况, 可见, 随着距离的变大, 预报风速的相关性系数呈指数级快速下降; 在距离为 100 km 时, 相关性系数下降至 0.8 左右; 而距离达到 400 km 时, 相关性系数已下降至 0.4 以下。空间相关性系数的显著变化验证了风速与局地效应的强相关性及空间风速分布的差异性。图4为气温的空间相关变化曲线, 可见, 随着距离的增大, 气温间的相关性也呈下降趋势, 但下降幅度有限; 在距离达到 400 km 时, 相关性系数仍在 0.96 以上; 因此, 在进行预测建模时, 气温的空间趋势性差异是可以忽略不计的。

3.2 空间特征提取

如上所述, 区域 NWP 有其空间一致性和差异性, 而风电场功率波动是气象参数的一致性和差异性共同作用的结果, 因此, 在对区域风电场群的功率进行集中预测时, 不同空间位置对应气象参数的趋势性和差异性必须考虑的。但是, 对于人工神经网络来说, 过多的输入参数必将导致网络结构的复杂化, 进而在训练过程中易陷入局部极值, 导致算法收敛速度慢甚至无法收敛。因此, 在采用人工神经网络进行风电集群建模时, 空间气象参数的特征提取是保证预测效果的关键。

主成分分析是一种以最小的信息丢失为前提, 将众多的原始变量综合为较少的几个互不相关的综合变量的方法^[20], 各主成分分量可在保留原变量主要信息的同时降低变量的维度。记 NWP 中对应气象参数矩阵为

$$\mathbf{Z} = \begin{bmatrix} z_{11} & \cdots & z_{1q} \\ \vdots & & \vdots \\ z_{p1} & \cdots & z_{pq} \end{bmatrix} \quad (5)$$

式中: q 为变量的个数, 即参与分析的 NWP 气象参数的个数; p 为样本数量。主成分分析的具体步骤如下:

1) 计算样本相关矩阵, 并计算其特征向量 \mathbf{S} 和特征值




图3 预报风速的空间相关性

Fig.3 Spatial correlation of forecast wind speed




图4 预报气温的空间相关性

Fig.4 Spatial correlation of forecast temperature

$$\mathbf{S} = \frac{1}{p-1} \sum_{w=1}^p (\mathbf{z}_w - \bar{\mathbf{z}})(\mathbf{z}_w - \bar{\mathbf{z}})^T \quad (6)$$

式中: $\bar{\mathbf{z}} = \sum_{w=1}^p \mathbf{z}_w / p$ 为样本均值; \mathbf{z}_w 为取自总体的样本, $\mathbf{z}_w = [z_{w1} \ z_{w2} \ \cdots \ z_{wg}]$ 。

2) 计算样本的主成分

$$\mathbf{y}_r = \mathbf{t}_r \mathbf{Z}, \quad r=1, 2, \dots, q \quad (7)$$

式中 \mathbf{t}_r 为不同特征值对应的正交特征向量。

3) 计算各主成分的贡献率

$$\delta_r = \lambda_r / \sum_{r=1}^q \lambda_r \quad (8)$$

式中 λ_r 为 \mathbf{S} 的特征值, $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_q \geq 0$ 。

贡献率反映了主成分反映原始变量信息的能力, 前 s 个主成分的贡献率之和为累计贡献率, 主成分个数取决于累计贡献率, 一般认为累计贡献率 > 85% 对应的前 s 个主成分即包含原始变量所能提供的主要信息^[20]。

4 算例分析

4.1 风电场集群划分

以本文 1.3 节描述的 34 个风电场为例进行算法

验证。为了保证算法的有效性, 仅以 2013-01—2013-09 的数据进行建模, 其余 3 个月的数据用于测试, 且测试样本集不参与建模的所有阶段。

以风电场实际功率序列构造观测数据矩阵, 采用式(1)~(5)描述的方法进行模糊聚类分析。图 5 为系统聚类树, 根据聚类中心距离最大原则^[21], 同时考虑各聚类间的样本均衡, 本文将聚类数量确定为 4 个, 即根据风电场出力特性, 将所有 34 个风电场划分为 4 个集群。

图 6 显示了风电场集群的位置分布, 图中星型、正方形、三角形和圆形分别对应由聚类得到的 4 个集群。其中集群 1 包含 6 个风电场, 主要分布在烟台北部沿海区域, 分布较为集中; 集群 2 有 7 个风电场, 包含潍坊北部沿海及临沂、泰安等地区的内陆风电场; 集群 3 包含 12 个风电场, 主要分布在威海、青岛等区域; 集群 4 包含 9 个风电场, 主要分布在渤海湾南部、东营东北部沿海区域。图 7 为 4 个集群对应风电场的日出力特性, 可见, 基于模糊聚类的集群划分较好地体现了风电场出力特性的差异。其中, 集群 1 地处渤海海峡处, 受渤海、黄海的双重影响, 日平均功率呈双峰双谷分布; 集群 2 多处于内陆, 无明显的日变化规律; 集群 3 在海陆风的作用下, 呈现典型的单峰单谷分布; 集群 4 同样受海陆风的影响, 但其地处三面环陆的渤海沿岸, 特殊的位置决定了其出力特性与集群 3 有较大差异。

4.2 空间特征气象参数提取

针对不同集群, 采用本文 3.2 节论述的主成分分析法对各集群对应 NWP 中不同气象参数的空间特征信息进行提取。图 8 显示了集群 3 中 12 个风电场对应 100 m 层风速预报结果的主成分分量序列图, 可见, 第 1 主成分主要体现了风速的趋势性变化, 第 2、3 主成分分别从不同角度反映了 12 组预测风速的差异性。图 9 为不同气象参数对应主成分分布的贡献率和累计贡献率的分布情况, 可见, 对于不同层高的风速而言, 第 1、2 主成分的累计贡献率 > 90%, 因此, 前 2 个主成分可反映该区域风速的整体变化趋势及差异化信息; 气温第 1 主成分的贡献率已 > 90%, 因此在进行气温特征参数提取时可直接选取气温的第 1 主成分; 动量通量反映了能量密度变化的情况, 从累计贡献率来看, 前 2 个主成分可反映动量通量序列的绝大部分信息。

4.3 功率预测

以集群划分为基础, 采用 BP 人工神经网络对




图 5 系统聚类树

Fig.5 Cluster tree of system



图 6 风电场集群分布

Fig.6 Distribution of wind farm clusters

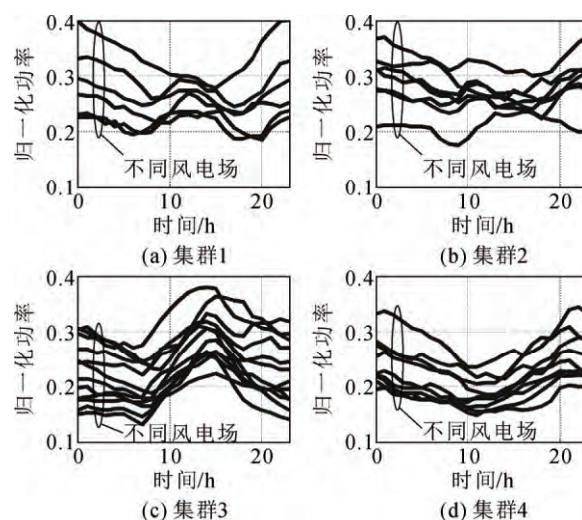


图 7 不同集群的功率特性

Fig.7 Power characteristics of different clusters

各集群分别进行建模, 其中, 神经网络的输入参数为本文 4.2 节提及的特征气象参数, 神经网络结构设置参照经文献[22]验证的参数, 即网络结构取 3 层, 隐层神经元个数通过遍历得到。方便起见, 记




图8 风速的主成分分量

Fig.8 Principal component of wind speed

集群预测方法为方案 1。为了验证本文算法的计算效率和准确性,同时采用另外 2 种方案进行建模。

方案 2: 各风电场分别建立神经网络预测模型,集群预测结果由集群内单个风电场的预测结果累加得到,区域预测结果由集群预测结果累加得到。

方案 3: 以全省风电功率总加为目标,选择所有风电场的空间几何中心处对应 NWP 为特征气象预报,并以此建立神经网络模型。

表 1 展示了不同方案预测结果的误差统计情况,其中误差指标选择文献[23]推荐的均方根误差、平均绝对误差及相关性系数。可见,对于不同集群来说,方案 1 的均方根误差总体大于方案 2,但 2 者的偏差保持在 1%以内;对相关性系数而言,方案 1 较方案 2 略有下降,最大偏差为 3%左右,该偏差主要是由 NWP 空间特征提取过程中因气象信息贡献率降低引起的。方案 1 与方案 2 对应预测结果的弱差异性证明了空间特征气象提取的合理性。

图 10 显示了不同预测方案对应的风电场总的预测结果的误差分布情况,可见,随着预测范围扩大,在区域平滑效应的作用下,方案 1 与方案 2 对应的误差指标差异基本消除。对于方案 3 来说,因单一气象预报难以反映区域的气象特性,方案 3 的预测精度较方案 1、2 仍有较大差距,均方根误差增大 4%左右,相关性系数下降达 10%。因此,从预测精度考虑,方案 1 与方案 2 是较好的选择。与此同时,相对方案 2 的 34 个风电场预测模型,方案 1 仅需对 4 个集群进行集中建模,可显著减少建模工作量,提高建模效率,具有较高的工程应用价值。

5 结论

1) 基于风电场功率序列的模糊聚类方法可实现对风电场出力特性的有效识别,并可对风电场集群进行合理划分。




图9 不同主成分的贡献率

Fig.9 Contributions of different principal components




图10 不同计算方案的误差

Fig.10 Errors of different calculation scheme

表 1 不同方案的误差比较

Table 1 Error comparison of different schemes

集群	方案	装机容量 /MW	平均绝对误 差	均方根误 差	相关性系 数
集群 1	方案 1	366.7	0.088	0.119	0.873
	方案 2		0.090	0.116	0.883
集群 2	方案 1	453	0.082	0.107	0.845
	方案 2		0.086	0.107	0.855
集群 3	方案 1	952	0.072	0.092	0.918
	方案 2		0.066	0.083	0.934
集群 4	方案 1	840.5	0.114	0.151	0.811
	方案 2		0.107	0.141	0.849
全部风电场	方案 1	2 612.2	0.065	0.081	0.921
	方案 2		0.065	0.080	0.925
	方案 3		0.089	0.116	0.821

2) 局地效应引起的区域气象分布差异显著,由主成分分析方法提取的气象参数可在反映区域气象特征一致性的基础上,在很大程度上保留区域气

象特征的差异性。

3) 基于集群划分的短期风电功率预测方法可实现对区域风电的快速建模与预测。单个集群的预测精度略低于传统逐风电场建模的预测精度, 随着预测范围的扩大, 集群预测与传统预测方法的精度相当, 但建模量显著降低。

参考文献 References

- [1] 国家能源局. 2015 年全国风电产业继续保持强劲增长势头[EB/OL].[2016-02-02]. http://www.nea.gov.cn/2016-02/04/c_135073627.htm.
National Energy Administration. The national wind power industry continued to maintain strong growth momentum in 2015[EB/OL].[2016-02-02]. http://www.nea.gov.cn/2016-02/04/c_135073627.htm.
- [2] 曹 阳, 刘 纯, 黄越辉, 等. 基于等效聚合的大型互联电网风电接纳能力[J]. 高电压技术, 2016, 42(9): 2792-2799.
CAO Yang, LIU Chun, HUANG Yuehui, et al. Wind power accommodation capability of large-scale interconnected power grid based on equivalent aggregation method[J]. High Voltage Engineering, 2016, 42(9): 2792-2799.
- [3] 杨德友, 温佳鑫, 陈家荣, 等. 用于提高风电场可调度性的储能系统预测控制策略[J]. 高电压技术, 2017, 42(3): 1043-1048.
YANG Deyou, WEN Jiaxin, CHAN Kevin, et al. Smoothing and dispatching the output of wind/battery energy storage hybrid system via model prediction control[J]. High Voltage Engineering, 2017, 43(3): 1043-1048.
- [4] 钱 政, 裴 岩, 曹利霄, 等. 风电功率预测方法综述[J]. 高电压技术, 2016, 42(4): 1047-1060.
QIAN Zheng, PEI Yan, CAO Lixiao, et al. Review of wind power forecasting method[J]. High Voltage Engineering, 2016, 42(4): 1047-1060.
- [5] CASSOLA F, BURLANDO M. Wind speed and wind energy forecast through Kalman filtering of numerical weather prediction model output[J]. Applied Energy, 2012, 99(6): 154-166.
- [6] FOLEY A M, LEAHY P G, MARVUGLIA A, et al. Current methods and advances in forecasting of wind power generation[J]. Renewable Energy, 2012, 37(1): 1-8.
- [7] HAQUE P M. Very short-term prediction of wind farm power: an advanced hybrid intelligent approach[C]// Industry Applications Society Annual Meeting. Addison, USA: IEEE, 2015: 1-8.
- [8] CHITSAZ H, AMJADY N, ZAREIPOUR H. Wind power forecast using wavelet neural network trained by improved clonal selection algorithm[J]. Energy Conversion & Management, 2015, 89(1): 588-598.
- [9] TASICARAOGLU A, UZUNOGLU M. A review of combined approaches for prediction of short-term wind speed and power[J]. Renewable & Sustainable Energy Reviews, 2014, 34(6): 243-254.
- [10] 冯双磊, 王伟胜, 刘 纯, 等. 风电功率物理预测方法研究[J]. 中国电机工程学报, 2010, 30(2): 1-6.
FENG Shuanglei, WANG Weisheng, LIU Chun, et al. Study on the physical approach to wind power prediction[J]. Proceedings of the CSEE, 2010, 30(2): 1-6.
- [11] 王 勃, 冯双磊, 刘 纯. 基于天气分型的风电功率预测方法[J]. 电网技术, 2014, 38(1): 93-98.
WANG Bo, FENG Shuanglei, LIU Chun. Study on weather typing based wind power prediction[J]. Power System Technology, 2014, 38(1): 93-98.
- [12] 张亚超, 刘开培, 秦 亮. 基于 VMD-SE 和机器学习算法的短期风电功率多层次综合预测模型[J]. 电网技术, 2016, 40(5): 1334-1340.
ZHANG Yachao, LIU Kaipei, QIN Liang. Short-term wind power multi-level combined forecasting model based on variational mode decomposition-sample entropy and machine learning algorithms[J]. Power System Technology, 2016, 40(5): 1334-1340.
- [13] 陈道君, 龚庆武, 金朝意, 等. 基于自适应扰动量子粒子群算法参数优化的支持向量回归短期风电功率预测[J]. 电网技术, 2013, 37(4): 974-980.
CHEN Daojun, GONG Qingwu, JIN Zhaoyi, et al. Short-term wind power prediction based on support vector regression machine optimized by adaptive disturbance quantum-behaved particle swarm optimization[J]. Power System Technology, 2013, 37(4): 974-980.
- [14] 梁 沛, 卢继平, 钟 璐, 等. 非迭代与分时段最优的风电功率短期预测[J]. 电网技术, 2015, 39(10): 2766-2771.
LIANG Pei, LU Jiping, ZHONG Lu, et al. Short-term wind power forecasting based on non-iterative algorithm and divided period optimization[J]. Power System Technology, 2015, 39(10): 2766-2771.
- [15] 陈 颖, 孙荣富, 吴志坚, 等. 基于统计升尺度方法的区域风电场群功率预测[J]. 电力系统自动化, 2013, 37(7): 1-5.
CHEN Ying, SUN Rongfu, WU Zhijian, et al. A regional wind power forecasting method based on statistical upscaling approach[J]. Automation of Electric Power Systems, 2013, 37(7): 1-5.
- [16] 别朝红, 安佳坤, 陈筱中, 等. 一种考虑时空分布特性的区域风电功率预测方法[J]. 西安交通大学学报, 2013, 47(10): 68-74.
BIE Zhaohong, AN Jiakun, CHEN Xiaozhong, et al. Regional wind power prediction considering temporal and spatial characteristics[J]. Journal of Xi'an Jiaotong University, 2013, 47(10): 68-74.
- [17] 施鹏飞, 杨校生, 许洪华, 等. 中国电力百科全书新能源发电卷[M]. 北京: 中国电力出版社, 2014.
SHI Pengfei, YANG Xiaosheng, XU Honghua, et al. China electric power encyclopedia new energy power generation[M]. Beijing, China: China Electric Power Press, 2014.
- [18] 刘燕华, 田 茹, 张东英, 等. 风电出力平滑效应的分析与应用[J]. 电网技术, 2013, 37(4): 987-991.
LIU Yanhua, TIAN Ru, ZHONG Dongying, et al. Analysis and application of wind farm output smoothing effect[J]. Power System Technology, 2013, 37(4): 987-991.
- [19] KALKSTEIN L S, TAN G, SKINDLOV J A. An evaluation of three clustering procedures for use in synoptic climatologically classification[J]. Journal of Climate and Applied Meteorology, 1987, 26(6): 717-730.
- [20] 任雪松, 余秀林. 多元统计分析[M]. 北京: 中国统计出版社, 2011.
REN Xuesong, YU Xiulin. Multivariate statistical analysis[M]. Beijing, China: China Statistics Press, 2011.
- [21] DE MULDER W. Instability and cluster stability variance for real clusterings[J]. Information Sciences, 2014, 260(3): 51-63.
- [22] 刘 纯, 范高锋, 王伟胜, 等. 风电场输出功率的组合预测模型[J]. 电网技术, 2009, 33(13): 74-79.
LIU Chun, FAN Gaofeng, WANG Weisheng, et al. A combination forecasting model for wind farm output power[J]. Power System Technology, 2009, 33(13): 74-79.
- [23] 风电功率预测功能规范: Q/GDW 588—2011[S]. 北京: 中国电力出版社, 2011.
Function specification of wind power forecasting: Q/GDW 588—2011[S]. Beijing, China: China Electric Power Press, 2011.



WANG Bo
Senior engineer
Corresponding author

王 勃(通信作者)
1983—, 男, 硕士, 高工
研究方向为新能源资源评价、功率预测、数值天气
预报等
E-mail: wangbo@epri.sgcc.com.cn

收稿日期 2017-07-15 修回日期 2017-09-20 编辑 程子丰